


Деревья решений: классификация и регрессия

Конспект к практическому занятию

1. Идея дерева решений

Объект проходит по условиям до конечного листа



Условная схема.

Дерево решений разбивает пространство признаков на области с помощью последовательности простых вопросов. Каждый вопрос сравнивает один признак с порогом: $x_i \leq t$? В зависимости от ответа объект направляется в левую или правую ветвь. В конце пути находится лист, который выдаёт предсказание.

- Корень — начальный узел, через который проходят все объекты.
- Внутренний узел — проверка условия и выбор ветви.
- Лист — конечная область и соответствующий ей ответ.
- Глубина — число переходов от корня до узла; глубина корня равна 0.

Каждый путь задаёт правило вида «длина лепестка больше одного порога и ширина лепестка меньше другого». Небольшое дерево можно интерпретировать как набор условий. Глубокое дерево тоже состоит из простых условий, но их совокупность уже трудно анализировать.

2. Что происходит при обучении и как получается ответ

Разбиение уменьшает смешение классов



5A + 5B: энтропия 1 бит



Только А: энтропия 0



Только В: энтропия 0

Синий — класс А; оранжевый — класс В. Условный пример.

При обучении дерево последовательно разделяет объекты на группы, в которых значения цели становятся более похожими. Далее оно повторяет ту же процедуру для каждой полученной группы — это рекурсивное разбиение.

В классификации смысл разбиения — уменьшить неопределённость относительно класса. Её можно измерять энтропией: она высока, когда классы сильно смешаны, и равна нулю,

когда все объекты группы принадлежат одному классу. Дерево выбирает разбиение, которое уменьшает среднюю энтропию дочерних групп с учётом их размеров.

Например, в узле 10 объектов: 5 класса А и 5 класса В. До разбиения оба класса одинаково вероятны, энтропия равна 1 биту. Если один дочерний узел получит только 5 объектов А, а другой — только 5 объектов В, энтропия обоих станет нулевой. Если группы останутся смешанными, уменьшение неопределённости будет меньше.

Это объясняет общую идею, а не конкретную настройку ноутбука: `DecisionTreeClassifier` там использует критерий Джини по умолчанию. Он тоже поощряет однородность классов; для явного использования энтропии задают `criterion='entropy'`.

В регрессии цель числовая. Поэтому вместо смешения классов дерево уменьшает разброс числовых ответов внутри групп. С критерием `squared_error` это означает уменьшение средних квадратов отклонений от среднего каждой группы.

Алгоритм действует жадно: выбирает локально лучшее разбиение на текущем шаге, не перебирая заранее все возможные продолжения. Это не гарантирует глобально оптимальной структуры. Новое разбиение применяется только к объектам текущего узла. Рост продолжается, пока разделение возможно и не достигнуты заданные ограничения.

Ответ в листе

Ответ определяется объектами обучающей выборки в листе

Классификация: 6A + 2B → A

Регрессия: 0,2; 0,3; 0,4 → 0,3

Большинство голосов

Среднее при квадрате ошибки

Новый объект проходит через уже найденные условия и попадает в один лист. Ответ определяется обучающими объектами этого листа:

- Классификация — голосование: выбирается наиболее частый класс. Если в листе 6 объектов А и 2 объекта В, ответ — А. При использовании весов учитывается суммарный вес объектов каждого класса.
- Регрессия — среднее значение цели при стандартном критерии `squared_error`. Если в листе значения 0,2; 0,3; 0,4, ответ — 0,3.

Все новые объекты одного листа получают одинаковый ответ. Дерево не пересчитывает условия и не ищет ближайших соседей на этапе предсказания. Правило среднего относится к стандартной регрессии с квадратом ошибки: при критерии абсолютной ошибки используют медиану.

3. Как оценивать качество классификации

В практике есть простая проверка на Iris: модель получает длину и ширину лепестка и предсказывает один из трёх видов цветка. Около 33% объектов отложено для теста.

`classification_report` показывает метрики отдельно для каждого класса:

- Precision: какая доля объектов, предсказанных как данный класс, действительно к нему относится.
- Recall: какая доля объектов данного класса найдена моделью.
- F1: гармоническое среднее precision и recall.
- Support: число истинных объектов класса в проверочной выборке.

Ассигасу — доля верных ответов по всем объектам. Macro average даёт классам одинаковый вес, weighted average — вес по support.

В сохранённом выводе все показатели равны 1,00 на 50 тестовых объектах: 19, 15 и 16 объектов трёх классов. Это результат конкретного разбиения, а не доказательство идеального качества дерева вообще.

4. Геометрия дерева и чувствительность к повороту




Иллюстрация из практики: слева исходные координаты, справа после поворота. Осевая граница становится ступенчатой.

Разбиение по одному признаку даёт границу, параллельную координатной оси. В двух измерениях последовательность таких разбиений образует прямоугольные области. Нелинейную зависимость дерево приближает комбинацией подобных областей.

В практике сначала строится датасет, где класс определяется знаком первого признака. Для него достаточно одного порога $x_1 = 0$. Затем обе координаты поворачиваются на 45° , а метки классов остаются прежними.

После поворота граница в новых координатах становится наклонной. Дерево не проводит одним условием диагональную прямую, поэтому приближает её ступенчатыми разбиениями. Информация не исчезла, но представление стало менее удобным для пороговых правил.

- Изменение единиц одного признака обычно сохраняет порядок объектов и доступные разбиения. Поэтому масштабирование не требуется так, как для kNN.
- Поворот смешивает признаки и может существенно изменить необходимую сложность дерева.

Эти свойства относятся к обычным деревьям с проверкой одного признака в узле. Численная точность и особенности реализации могут создавать небольшие отличия даже после преобразований, сохраняющих порядок.

5. Переобучение: пример make_moons




Иллюстрация из практики: дерево без ограничений и `min_samples_leaf=4`. Показаны обучающие данные, а не независимая проверка.

`make_moons` создаёт два нелинейно расположенных класса в форме полумесяцев. В практике используются 100 объектов с шумом `noise=0.25`. Сравниваются дерево без ограничений и дерево с `min_samples_leaf=4`.

Неограниченное дерево может строить маленькие области вокруг отдельных шумных наблюдений. Так оно улучшает соответствие обучению, но рискует принять случайные отклонения за закономерности.

`min_samples_leaf=4` разрешает только такие разбиения, после которых в каждом дочернем листе остаётся хотя бы четыре обучающих объекта. Это препятствует созданию одиночных листьев и обычно делает границу менее дробной.

График показывает сами обучающие точки. Он помогает понять форму модели, но не измеряет её обобщающую способность. Улучшение на новых данных нужно проверять валидацией, а не только внешним видом границы.

6. Как ограничивать сложность дерева

В практике сравниваются `max_depth` и `min_samples_leaf`. Это способы регуляризации: они уменьшают свободу модели ради более устойчивого решения.

- `max_depth` ограничивает длину пути. При глубине d у бинарного дерева не более 2^d листьев, но фактическое число может быть меньше.
- `min_samples_leaf` задаёт минимальное число объектов в каждом листе и отсекает слишком мелкие разбиения.
- `min_samples_split` задаёт минимальное число объектов в узле для попытки его разделить. Оно не гарантирует минимальный размер каждого нового листа.

Слишком слабые ограничения позволяют подстроиться под шум; слишком сильные мешают описать реальную зависимость. Параметры выбирают по проверочному качеству, а не по минимальной ошибке на обучении.

Есть и другие ограничения: `max_leaf_nodes` ограничивает число листьев, `min_impurity_decrease` — минимальное улучшение от разбиения. `ccp_alpha` управляет обрезкой дерева по компромиссу между ошибкой и числом листьев. В практике такая обрезка не исследуется.


Фиксированный `random_state` помогает воспроизвести обучение, в том числе при неоднозначном выборе равнозначных разбиений. Это не регуляризация: воспроизводимое дерево всё ещё может переобучаться.

7. Регрессия: ступенчатое приближение зависимости

В ноутбуке создаются 200 наблюдений зависимости $y = 4(x - 0,5)^2$ с добавленным шумом. Дерево разбивает диапазон x на интервалы и в каждом предсказывает среднее обучающих значений цели.

Поэтому результат — ступенчатая функция, а не гладкая парабола. Положение объекта внутри одного листа не меняет ответ. За пределами обучающего диапазона дерево тоже выдаёт значение существующего листа и не продолжает тренд параболы. Это ограничивает его способность к экстраполяции.

Сначала сравниваются `max_depth=2` и `max_depth=3`. Первое дерево может иметь до четырёх листьев, второе — до восьми. Большая глубина позволяет создать больше интервалов и точнее приблизить кривую.




Глубина 2 и глубина 3: больше листьев позволяет разбить диапазон на большее число интервалов.

Но дополнительные интервалы могут описывать как полезную форму, так и случайный шум. Более точное приближение обучения не обязательно означает меньшую ошибку на новых данных.

Затем сравниваются дерево без ограничений и дерево с `min_samples_leaf=10`. Первое может создавать почти индивидуальные ответы для наблюдений; второе усредняет не менее десяти объектов в каждом листе и обычно даёт менее раздробленную функцию.

Это «сглаживание» за счёт более крупных групп, а не получение непрерывной гладкой функции. На границах листьев скачки остаются.



Слева дерево без ограничений, справа `min_samples_leaf=10`. Более крупные листья уменьшают дробность предсказаний.

В этих фрагментах обе модели обучаются и рисуются на одном наборе данных. Плотная сетка x нужна для отображения предсказаний, но не является независимым тестом. Численные метрики регрессии и CV здесь не вычисляются.

Вертикальные линии на графике глубины прописаны вручную. При повторении эксперимента фактические пороги нужно брать из обученного дерева, а не считать эти числа универсальными.

8. Запоминание выборки и обобщение

Если признаки позволяют отделить все объекты и ограничения достаточно слабы, дерево может выделить каждому наблюдению собственный лист. На обучении это даёт правильную метку или точное числовое значение.

При совпадающих признаках и различных целях идеальное разделение может быть невозможно. Поэтому тезис «датасет можно идеально выучить одиночными листьями» требует оговорки о разделимости объектов.

Даже когда обучение воспроизведено точно, это не доказывает способность предсказывать новые наблюдения. Смысл завершающего тезиса практики — не отсутствие обучения как процедуры, а отсутствие полезного обобщения при запоминании случайных деталей.

Одиночное дерево может быть неустойчивым: небольшое изменение данных меняет верхнее разбиение, а затем и нижние ветви. Ограничения сложности уменьшают этот риск, но их эффект оценивают по независимой проверке.

Главный вывод: дерево строит нелинейное предсказание из простых правил. Его полезность определяется не способностью идеально воспроизвести обучение, а тем, насколько эти правила сохраняют смысл на новых объектах.